

Low-Temperature Single-Sample Decoding of a Two-Layer Sound–Word Canvas Model for Thai *Klon Pad*

Worasait Suwannik*

Abstract

We present a generator of Thai *klon pad* (กลอนแปด) verse, one stanza from a short topic, and evaluate it against human verse on held-out topics. The generator is a masked language model initialised from WangchanBERTa over a fixed canvas with two layers: a sound layer of pronounced syllables, where rhyme, tone and syllable count are enforced as hard masks, and a word layer of whole words, so that no word is cut into written pieces. Decoding commits one cell at a time and samples at temperature 0.4; one sample is drawn per topic, with no selection, reranking or repair. On 78 held-out titles never used in development, judged by three independent runs of a frozen LLM judge in the same pools as human verse written for the same topics, 70.5% of the generated stanzas pass form, lexical cleanness of all four lines and topic alignment together, against 76.9% for the human stanzas (difference -6.4 points, 95% CI $[-19.2, +6.4]$). Cleanness is level with human (85.9% vs. 87.2%), and the stanzas pass form and cleanness together slightly more often than the human ones ($+3.8$ points, $[-6.4, +14.1]$); the difference lies in alignment (84.6% vs. 91.0%), on topics that were written from the human stanzas. On the same titles the same model passes 55.1% at temperature 0.6 and 44.9% at 0.8: lexical errors lie in the model’s lower-probability choices, and sharpening the sampling distribution removes most of them, at a cost in vocabulary (7.5% rare words against 16.5% in the human stanzas) and diversity. A development test that holds the decoder’s topic bonus and repetition penalty at their temperature-0.8 strength keeps 0.92 of the gain, so the gain comes from sharper sampling rather than from those terms. The pre-registered target, all-three within 5 points of human, is missed by 1.4 points. KlonSuphap-LM, the only public *klon pad* generator we know of, passes none of the 78 held-out titles in the same pools (form 19.2%, cleanness 3.8%).

1 Introduction

Klon pad (กลอนแปด, “eight-syllable verse”) is the most widely practised form of Thai verse. A stanza (บท, *bot*) has four lines (วรรค, *wak*) of nominally eight syllables, linked by a fixed scheme of external rhymes, with tone constraints on line-final syllables (Section 3.1). Two properties of Thai make it a hard target for a neural generator. Thai script does not mark word boundaries, so a model that works on written subword pieces can produce strings that are not words. And the rhyme is defined on pronounced syllables, which do not always coincide with written ones: โจน is read จะโจน. A generator therefore has to satisfy position-specific phonological constraints while writing ordinary, well-formed Thai.

Goal. Our target was fixed before the evaluation reported here, in a pre-registration released with the code (Appendix A): on held-out topics, the share of generated stanzas that pass form, are lexically clean in all four lines and are on topic (“all-three”) should be within 5 percentage points of the share for human verse on the same topics, judged in the same pools. Two earlier held-out evaluations under the same protocol, of predecessor configurations (an earlier generator that drew 64 samples per topic and kept the one an LLM ranker preferred), each on its own fresh titles and human controls and with three independent judge runs,

*The research reported here was directed by Worasait Suwannik. The programs were produced by Claude, Anthropic’s AI model. Worasait Suwannik contributed to the design of the model, including a whole-stanza canvas with a sound layer of pronounced syllables for the form constraints and a word layer of whole words for spelling and naturalness; to the experimental design, including LLM-written topics for reply stanzas; the wording of the cleanness judge prompt; and the unusual-topic test of Appendix E and the selection of its topics.

missed it widely (44.7% against 63.1%, and 35.8% against 60.5%), in both cases because of cleanness; the human rate differs between evaluations because each has its own titles, human stanzas and pools. The system described here comes within 6.4 points (70.5% against 76.9%): the target is missed by 1.4 points, and the 95% interval of the difference, $[-19.2, +6.4]$, is too wide to separate the system from human verse in either direction.

This paper describes a generator built for these two properties and evaluates it against human verse on topics it never saw. Its contributions are:

1. A two-layer canvas model (Section 4, Figure 2): one cell per pronounced syllable, on which rhyme, tone and length are hard masks, carrying whole-word tokens over an open vocabulary initialised from WangchanBERTa, decoded by confidence-ordered commitment at a low sampling temperature, one sample per topic.
2. A held-out evaluation (Section 3): 78 titles excluded from every stage of development, human verse for the same topics judged in the same pools, a form checker and two frozen LLM-judge instruments run three times independently.
3. The sampling temperature as the method’s main ablation: on the same held-out titles, all-three rises from 44.9% at temperature 0.8 to 70.5% at 0.4, cleanness from 56.4% to 85.9%, and the number of judged-bad lines falls from 36 to 13 of 312; we explain this by where lexical errors sit in the model’s distribution, and measure what it costs in vocabulary and diversity (Sections 5–6); a confound test attributes the gain to the sampling itself, not to decoder bonuses that temperature also amplifies.
4. A comparison with KlonSuphap-LM [33], run locally with its temperature tuned on development topics, in the same held-out pools (Section 5.4).

2 Related Work

Thai poetry generation. Published work on generating Thai verse is sparse. The only public *klon pad* generator we know of is KlonSuphap-LM [33], a Thai GPT-2 base model fine-tuned on about 65,770 couplets (กอน, two lines each) of *klon pad* from the Thai Literature Corpora [27]. It marks the words that must rhyme with special tags in the training text (a tag pair for the source and the target of each rhyme within a stanza, and another for the rhyme between stanzas), optionally masks attention to non-rhyme words, and then fine-tunes with proximal policy optimisation (PPO) against a rule-based form grader. It is documented by a model card and code repository rather than a paper, and reports no evaluation of meaning or fluency; form is learned softly from the tags and the reward, whereas our decoder enforces rhyme, tone and length as hard masks on pronounced syllables. The ThaiProsody benchmark [34] evaluates large language models composing four Thai verse forms, *klon pad* among them, with a deterministic rule checker for tone, weight and rhyme, a model-based syllable counter and an LLM content judge; it is a benchmark of general-purpose models prompted zero-shot rather than a trained generator. Other neural work on Thai verse classifies or analyses poems rather than writing them [24, 30]. Public Thai poem collections include the Thai Literature Corpora [27], drawn from classical works, and the klongklon dataset [25], more than 50,000 *klon pad* and *khlong si suphap* poems collected from various literature, among them classical works such as Phra Aphai Mani; our training data are instead modern verse written by forum members, and our evaluation compares against human verse written for the same topics. We are not aware of a published *klon pad* generator evaluated against human verse on held-out topics; we evaluate KlonSuphap-LM under our protocol in Section 5.4.

Thai language models. The generator’s body is WangchanBERTa [19], a RoBERTa-style masked language model pretrained on Thai text with a SentencePiece vocabulary. Segmentation and grapheme-to-phoneme conversion use PyThaiNLP [22] and TLTK [1]. We use a masked encoder rather than a left-to-right generative model because the canvas is filled in any order under position-specific constraints, and because WangchanBERTa’s pieces give an initialisation for every whole word of the open vocabulary.

Constrained poetry and lyric generation. Neural generation of metrical verse has concentrated on Chinese and English. Chinese quatrain generation conditioned on keywords [35] treats tonal pattern and rhyme as learned or filtered properties. Hafez [8, 9] combined a language model with a finite-state acceptor

that admits only metrical, rhyming paths, the closest antecedent of our hard masks. Deep-speare [17] learned meter and rhyme jointly with the language model; Tian and Peng [29] plan content and rhyme words before writing sonnet lines; and constrained decoding has been applied to Sanskrit meter [15]. For rigid-format text, SongNet [18], motivated by lyrics and evaluated on SongCi and sonnets, controls the format with format and rhyme symbols at each position, a fixed grid like our canvas; for lyrics, DeepRapper [32] writes rap lines right to left so that the rhyme is chosen first. CIGEN [28], the work nearest in spirit to ours, composes Chinese Ci non-autoregressively so that generation accommodates the tune pattern’s rigid format of length and rhyme. PoetryDiffusion [13] writes sonnets and SongCi with a continuous diffusion model, which noises continuous word representations towards a Gaussian, for the semantics, and a separately trained metrical controller that penalises states straying from the target control distribution; its form control is soft, where ours is a hard mask. A shared design question is when the rhyme word is chosen relative to the rest of the line. Our decoder chooses the rime family early from the model’s own probability over rime families (Section 4.2), writes it into the sound layer, and lets the words of the whole stanza be filled around it in confidence order. A second difference is the unit: because Thai rhyme lives on pronounced syllables and Thai script does not delimit words, we keep two aligned layers, sounds for the constraints and whole words for the text, instead of constraining written subword tokens. Sound has also been given to masked language models as extra input embeddings: PoemBERT [14] adds sentiment and pinyin embeddings to a BERT-based Chinese poem generator. Our sound channels are also input embeddings, but the sound layer is in addition the surface on which the form constraints act.

Constrained and non-autoregressive decoding. Lexically constrained beam search [11] and Neuro-Logic decoding [20] enforce constraints in left-to-right generation. Our generator is a bidirectional masked language model [7] used non-autoregressively. Sampling from BERT by iterative re-masking [31], Mask-Predict [10] and MaskGIT [4] fill a fixed-length canvas over several steps. MaskGIT keeps the most confident predictions at each step and re-predicts the rest; Mask-Predict predicts all tokens at every step and re-masks the least confident ones, so earlier predictions can change. Our decoder instead commits one cell per step, the open cell whose best admissible token is most confident, and does not re-mask committed cells. Our training, which masks a randomly drawn share of each stanza (Section 4), is close to absorbing-state discrete diffusion: in D3PM an absorbing ([MASK]) state reduces to a reweighted masked-LM objective [2], and the MDLM objective is a weighted average of masked-LM losses [26]. These models do not order unmasking by the model’s confidence at decoding time; that ordering is the one of Mask-Predict and MaskGIT. The difference is that our constraints are hard masks on a parallel sound layer, so every intermediate canvas stays inside the form.

Sampling temperature. Holtzman et al. [12] showed that the low-probability tail of a language model is unreliable and that pure sampling from it produces incoherent text, motivating nucleus sampling. Peeperkorn et al. [21] found that in story generation temperature is only weakly related to novelty and moderately related to incoherence. Our temperature comparison is a measurement of the same trade-off in a constrained, non-autoregressive generator, against human verse on held-out topics: the tail holds most lexical errors, and sharpening the distribution removes them at a measurable cost in vocabulary. Best-of- N selection with a learned verifier [6] is the usual alternative for avoiding bad samples after the fact; the method here draws one sample with no selection.

LLM judges. LLMs have been used as judges of generated text since early studies [5, 36], with known position and verbosity biases [36]; for creative writing, LLM judgments agree poorly with expert readers [3]. Our cleanness instrument adapts the error-span protocol of GEMBA-MQM [16] and asks a narrow question (is each span well-formed Thai) rather than a judgment of quality; we add fixed human anchor stanzas in every pool, blind interleaving with human verse, three independent judge runs, and report the judge’s disagreement with a human reader as a limitation (Section 7).




Figure 1: Skeleton of one *klon pad* stanza as checked in this work. Circles are pronounced syllables, drawn at the usual eight per line. Group A links the last syllable of line 1 to the 3rd syllable of line 2 (or the 5th, dashed); group B links the last syllable of line 2 to the last of line 3 and to the 3rd (or 5th) syllable of line 4. Line-final tones are on the right.

3 *Klon Pad*, Data and Evaluation Setting

3.1 The skeleton of a *klon pad* stanza

A stanza (บท) has four lines (วรรค), traditionally named วรรคสดับ, วรรครับ, วรรครอง and วรรคส่ง. Each line has 7–9 pronounced syllables, usually 8; in the training stanzas 73–81% of lines have 8 and 18–24% have 9, depending on the line. The form checker used throughout this work (released with the code, Appendix A) reads a stanza as follows; Figure 1 shows the skeleton.

- **Syllables.** Each line is segmented into words with PyThaiNLP [23] using its default `newmm` tokenizer, a dictionary-based maximum-matching segmenter [22], and each word is converted to phonemes with TLTK [1], giving pronounced syllables with onset, vowel, coda and tone. A line passes the count when it has 7–9 syllables, where short unstressed syllables (*e.g.* สะ, กระ) may count as one, as half or not at all; a line of 10 pronounced syllables that contains such light syllables can therefore pass, which is why the training data and the canvas below allow up to 10 syllables per line.
- **External rhyme.** Two syllables rhyme when they have the same *rime*, the vowel and the final consonant (rimes are grouped into *rime families*, with the ๑/๑/-๕๒ ~ -๑๒ and ๓-๑ ~ -๑๒ families merged, because the phoneme converter is inconsistent about their length). Three links are required: the last syllable of line 1 with the 3rd or 5th syllable of line 2 (group A); the last syllable of line 2 with the last of line 3; and the last syllable of line 2 with the 3rd or 5th syllable of line 4 (group B). Since lines 2 and 3 end on the same rime, the last link is equivalently a rhyme between the end of line 3 and the 3rd or 5th syllable of line 4. The link from the end of line 4 to the end of line 2 of the next stanza applies only to multi-stanza poems and is not used here.
- **Repeated rhyme word.** A rhyme link may not be made by repeating the same syllable of the same word.
- **Tones.** The last syllable of line 2 must not carry the สามัญ (mid) or ตรี (high) tone, so it carries เอก, โท or จัตวา; the last syllables of lines 3 and 4 must carry สามัญ or ตรี. The end of line 1 is free.

A stanza passes form when all four counts, the three links and the three tone rules hold, no rhyme word is repeated, and it contains no Chinese, Japanese or Korean script (a guard for generators with multilingual vocabularies; it never fires on the method, whose vocabulary is Thai only). Internal rhymes (สัมผัสใน) are an ornament and are not required. Poets bend these rules: 92.3% of the human stanzas in the held-out evaluation pass the checker, and 95.0% of the training stanzas.

3.2 Training data

The corpus is member-written modern verse crawled from the public boards of a Thai poetry forum, *klon-thaclub.com* (บ้านกลอนไทย), whose 29 boards used here cover love, longing, encouragement, festivals, dharma and a practice room for the prosody rules. Posts are cut into four-line stanzas; a stanza is kept when its line count and syllable counts are well formed and all three external rhyme links hold (tones are not filtered),

and duplicates are removed. The training split has 50,788 stanzas from 3,956 threads: 11,601 from opening posts and 39,187 from replies. The data pipeline of the two-layer model further keeps a stanza only when every line has 7–10 pronounced syllables, every syllable is read by the phoneme converter, and the words, re-joined and re-segmented, give back exactly the same sounds; 49,194 stanzas remain, of which a random 1,000 are held out to monitor the validation loss and 48,194 are used for training.

The conditioning topic of every training stanza, opening post or reply, is its thread title after removing decoration (symbol runs, repeated punctuation, reply prefixes, bracketed notes, decorative Latin letters).

3.3 Train/test split and the held-out titles

The corpus is split by thread title, not by stanza. Titles are first grouped on their Thai-only normalisation (the *title key*), so that decorated duplicates of one title (ผินร้าย and the same title framed by star symbols) cannot fall on both sides. The split has 3,821 training titles in 3,700 title groups (50,788 stanzas) and 659 test titles in 652 title groups (8,680 stanzas). A stanza-level split would leak, because a title’s content syllables occur in a sibling stanza of the same thread 22.4% of the time, as often as in the stanza itself (22.5%).

For the evaluation, every test title group that had been used anywhere in development was excluded. A group was out if its title key matched any title, prompt or topic used anywhere in development (every prompt file, every judged pool, every judged batch), or if any of its threads had supplied a human stanza to a judged pool or had a line found in a judged batch. The exclusion list holds 4,856 title keys from all these sources and 396 test threads (388 threads of human stanzas used in earlier pools, together with the threads found by their lines). Of the 652 test title groups (690 threads), 552 were excluded, leaving 100 (110 threads, 1,279 stanzas). None of the 100 titles was usable as a prompt as it stood; the reasons included birthday greetings, contest announcements, threads of ornamental *klon bot* forms, titles with Latin letters and one-syllable titles. A fixed rule therefore took, for each of the 100 title groups, its first reply stanza whose topic, written from that stanza by Claude Opus 5.5 under a fixed guide, is 2–12 syllables of Thai only (no Latin letters, digits or stray combining marks), contains none of a fixed list of forum keywords (meta and event words such as วันเกิด, ประกาศ, สมาชิก, กระหู่) and is neither a title or prompt used in development, a training title, nor a topic that Claude wrote for training stanzas during development (the model evaluated here was trained on thread titles only). That stanza is the **human control** and its topic is the **prompt** for the generator as well (Section 7 discusses how this selection may bias alignment). 78 titles qualified and 22 were dropped. Development used 49 further test-split titles, the *49 development topics* below, which are therefore among the excluded groups. When the evaluation ran, the exclusion of the 78 endpoint titles and their human controls was checked again against a fresh scan of every prompt, pool and judged line (the 388 pool threads and 53,728 judged lines): zero overlap.

Because each prompt was written from its human control, it may fit that stanza better than any other poem, which favours the human arm on alignment. Two further human stanzas per title were judged in the same pools as fillers; they balance the pools and are never an endpoint. Where the title had enough replies (138 of the 156 filler slots) they are the two earliest other reply stanzas under the same title (6 of them from a second thread with the same title), each under its own Claude-written topic; the other 18 slots hold human controls of the second earlier evaluation (Introduction), 11 reply stanzas under Claude-written topics and 7 opening-post stanzas under their thread titles. Fillers are exempt from the exclusion rule because they are never endpoints. The human controls are amateur forum verse: 17 of the 78 come from the forum’s birthday-verse board.

3.4 Passing criteria and the judge

A stanza passes **all-three** when (i) it passes the form checker of Section 3.1, (ii) all four of its lines are judged clean, and (iii) its topic alignment is judged at least 4 of 5. The marginal rates are reported beside the conjunction.

Cleanness. The cleanness instrument (Appendix B) adapts the error-span protocol of GEMBA-MQM [16]. The judge marks exact spans that are not linguistically well formed Thai: non-words, unrecognisable misspellings, unnatural word formations, and unnatural combinations of words that disrupt reading. A span is *critical* if it makes the line incomprehensible and *major* if a native reader stumbles but understands, or if it

is a non-word other than a genuine Thai prefix or suffix that can attach to the neighbouring word; something technically odd that does not disrupt reading is a pass. Because the text is verse, abstraction, metaphor, personification, archaic or poetic diction, unusual imagery and natural poetic compounds are explicitly not errors, and rhyme, syllable count and structure are not judged. A line is clean when it carries no critical or major span.

Alignment. The alignment instrument (Appendix B) asks the judge to write one Thai sentence saying what the poem is about, then score 1–5 how much of it stays on the topic, judging subject matter only and accepting figurative treatment (5: every line on topic; 4: at most one line wanders; 3: partly; 2: touched once and left; 1: unrelated). A stanza is aligned when its score is at least 4.

Runs, aggregation and agreement. The judge is Claude Opus 5.5, run as an agent: a conversation whose only tool use is reading the batch files and writing its verdict file. Both prompts are frozen and wrapped in a fixed agent instruction (Appendix B). Each instrument is run three times independently, each run judging all six pools of the instrument in one conversation (Section 7): a line is clean when at least two of the three runs report no critical or major span on it, and alignment is the median of the three scores; an item missing from a run counts in that run as unclear on every line and as alignment 1. Fleiss’ kappa across the three runs, over all items except the anchors, is 0.76 for per-line cleanness and 0.84 for alignment ≥ 4 .

Pools, anchors and blinding. The 78 titles are split into six parts of 13. Each part has one cleanness pool and one alignment pool holding, for each title, the three system arms (temperatures 0.4, 0.6 and 0.8), the human control and the two fillers, plus 16 *anchor* stanzas: human stanzas from a fixed anchor set, the same in every pool, used to detect judge drift (about 17% of items). Items are interleaved and keyed at random and dealt into batch files of about ten items plus about two anchors, texts are given raw, and the agent instruction tells the judge that the pool mixes system and human poems without labels. A pool-run is void if its anchors are under 70% clean or their median alignment is under 3; none was. Anchors were clean in 100%, 87.5% and 81.3% of cases in runs 1, 2 and 3.

Statistics. The primary comparison, fixed before any judging, is all-three at temperature 0.4 against the human controls; the other temperatures, the marginals, kappa and vocabulary and diversity read-outs are secondary. Differences use topic-clustered percentile bootstrap intervals (10,000 resamples of titles, seed 0, arms resampled together), and discordant titles are tested with the exact McNemar test.

4 Method

4.1 Two-layer canvas model

A stanza is a fixed canvas of cells preceded by the topic: a leading <s> cell, 12 topic cells and four lines of 10 cells (Figure 2). The model has two aligned layers.

Sound layer. One cell per pronounced syllable, computed as the form checker computes it (newmm words, then TLTK grapheme-to-phoneme per word), carrying three channels: onset, rime family and tone. The syllable count of a line is its number of cells, and rhyme and tone masks act on these sounds, so **ใจน** fills two cells, **จ** and **ใจน**, and its rhyme is that of **ใจน**. In the model used here the sound of a filled cell is derived from its word-layer token; a masked cell has no sound input, except that a rhyme cell whose rime family has been chosen receives that rime in its rime channel.

Word layer. The token at a cell is a pair (w, k) : word w and the position k of the cell’s syllable within it, so a word is never cut into written pieces. Its input embedding is $e_w + e_{(k, n_w)}$, where n_w is the number of syllables of w , plus the embeddings of the three sound channels, of the line (topic or poem line 1–4), of the cell’s position within its line and of its role (topic cell or poem cell of a given line), plus WangchanBERTa’s pretrained position embeddings; the sum passes through WangchanBERTa’s embedding layer normalisation. The vocabulary is open: 62,665 words, 24,814 seen in the 49,194 stanzas of the data pipeline (training and




Figure 2: The generator. Left: the network, a WangchanBERTa encoder over a canvas of topic cells and 4×10 poem cells, each cell carrying a whole-word token (word layer) and its pronounced syllable (sound layer). Right: one decoding step, repeated until every poem cell is filled (one step per cell, 32.9 on average on the held-out titles); rhyme, tone and length masks act on the sound layer; word-boundary masks and the sampling act on the word layer.

validation) and 37,851 never seen in them (from PyThaiNLP's word list and whole-word WangchanBERTa pieces), each kept only if it is Thai, readable by the phoneme converter, at most 8 syllables and re-segmented as itself. Every word row starts from the mean WangchanBERTa embedding of its pieces (86% of word tokens are exactly one piece); rows of never-seen words stay frozen, with one learned bias offset for the group. On test stanzas the open vocabulary lowers the share of stanzas with an out-of-vocabulary word from 14.0% (with the training-stanza words alone) to 2.3%.

Body and output. The body is the pretrained WangchanBERTa-base encoder [19] (12 layers, width 768); padding is never attended, and the $\langle s \rangle$ cell is always attended. Its hidden state at a cell passes through WangchanBERTa's pretrained masked-LM head transform to z_i , and the logit of token (w, k) is $z_i \cdot e_w + z_i \cdot e_{(k, n_w)} + b_w$, tied to the input rows, where b_w is a per-word output bias initialised from the centred, add-one-smoothed log frequency of w in those stanzas (frozen for never-seen words, which share the learned offset above). The *word-slot tokens* are all pairs (w, k) with $k \leq n_w$, 164,822 in all; the cross-entropy over all of them is computed exactly, without forming every logit, by factorising its normaliser over words.

Training. Training is masked prediction with one masking scheme per stanza: whole words (40%, a share of the words drawn uniformly from $[0.15, 1]$), single cells (20%, a share of the cells drawn the same way), lines j to 4 for a start line j drawn uniformly from 1–4 (25%) and every cell (15%). At masked rhyme cells the rime is revealed in the sound channel with probability 0.5, matching decoding, where the rime family is chosen before the word. The model was trained for 24 epochs with AdamW (weight decay 0.01 on all parameters except the per-word output biases, the shared offset, the $\langle s \rangle$ cell vector and the pretrained position embeddings), batch 32 and a one-cycle learning-rate schedule peaking at 3×10^{-5} after 6% of the 36,144 steps, with gradient clipping at 1.0 and seed 0; the weights after the last epoch are used. Training took about 8.7 hours on an Apple-silicon GPU. In development, 24 rather than 12 epochs raised all-three

by 8.2 points (95% CI [+2.9, +13.7]; one judge run, single samples with no selection on the 49 development topics with ten seeds each).

4.2 Decoding

Decoding starts from a canvas whose poem cells are masked, with a length for each line sampled from a table of line lengths measured on human stanzas (7–10 syllables, mostly 8). Each step runs the model once and then (Figure 2, right):

1. scores every open cell: to the model’s logits it adds a bonus of +1.5 on the tokens of the topic’s words (the lexicon words of more than one character among the 12 topic cells), cleared in a line once a topic word is completed there, and a penalty of -2 on words already placed; it applies the hard masks: the first cell of a line admits only the first syllable of a word and the last cell only the last syllable, line-final cells admit only the allowed tones (Figure 1), and a stutter ban forbids a token whose sound equals its neighbour’s in the same line unless the two cells belong to one lexicon word or the word pair is attested as a same-sound join at least twice in the 49,194 stanzas of the data pipeline (602 of 1,613 pair types are allowed, e.g. รัก|รัก, นาน|นาน); each cell is normalised to log-probabilities before the stutter ban (and, once chosen, the rime-family and group-word masks of step 2) remove tokens, without renormalising;
2. at the fifth step only, once four cells have been committed, chooses each rhyme group’s rime family: family f is drawn with probability proportional to $\exp(s_f/0.5)$, where s_f is the mean, over the group’s line-final cells and its 3rd-syllable receiver, of the log of the probability mass that the cell gives to f as scored in step 1; the family temperature 0.5 is fixed and T does not affect it, and the two groups always receive different families. The receiving cell is the 5th syllable if the chosen rime has more mass there than at the 3rd, and otherwise the 3rd; when it is the 5th, the 3rd may not carry that rime. The rime is written into the rime channel of the group’s open cells, so that the words are then chosen to fit it, and from then on rhyme cells admit only their group’s rime and no word may appear twice in a rhyme group. Until this step the rhyme cells are held, so the first four steps write only other cells;
3. keeps only the 512 best tokens of each cell;
4. commits one cell: the open cell whose best admissible token has the highest log-probability. A token (w, k) is admissible only if the whole span of w fits in the line around that cell and every other cell of the span admits the matching syllable of w . The token is sampled with probability proportional to $\exp(s/T)$, where s is its log-probability at that cell and $T = 0.4$; the other cells of w ’s span are then forced to the matching syllables of w and committed in later steps, so every syllable belongs to a real word.

A stanza takes one forward pass per syllable cell, 32.9 on average on the held-out titles (31–36). If the checker’s re-segmentation of the joined words disagrees with the cells, or no open cell has an admissible token, the stanza is decoded again, continuing the same random stream; this validity retry is allowed at most four times, after which the last attempt is kept, and at $T = 0.4$ it never occurred on the 78 held-out titles. Apart from it, one sample is drawn per topic (seed 0); there is no best-of- N , no reranker, no rejection on quality and no line repair. On one Apple-silicon laptop GPU the 78 held-out stanzas took 126 seconds including model loading, about 1.6 seconds per stanza.

5 Results

Against human verse. The method passes all-three on 55 of 78 titles (70.5%, 95% CI [60.3, 80.8]) and the human stanzas on 60 (76.9%, [67.9, 85.9]). The paired difference is -6.4 points ($[-19.2, +6.4]$); the method passes where the human stanza fails on 11 titles and the reverse holds on 16 (exact McNemar $p = 0.44$). As a share of the human rate the method reaches 0.917 ([0.762, 1.091]). Table 1 gives all rates; Appendix C shows 30 of the 55 passing stanzas.

Where the difference lies. The method is 6.4 points below human on alignment ($[-17.9, +3.8]$; 7 vs. 12 discordant titles) and 3.8 points above on cleanness and form together ($[-6.4, +14.1]$; 11 vs. 8). On cleanness alone it is 1.3 points below ($[-11.5, +9.0]$; 7 vs. 8). It passes form more often than the human stanzas ($+6.4$, $[0.0, +12.8]$), because poets bend the checker’s rules. The alignment difference is in the direction predicted

Table 1: Held-out evaluation: 78 titles, one sample per title and temperature, three independent judge runs per instrument, all arms and the human control in the same pools. Differences are against human with 95% topic-clustered bootstrap intervals; pp = percentage points. The fillers row gives the first and the second filler of each title.

Arm	All three	vs. human (pp)	Clean	Aligned ≥ 4	Form	Clean & form
$T = 0.4$ (the method)	70.5%	-6.4 [-19.2, +6.4]	85.9%	84.6%	98.7%	84.6%
$T = 0.6$	55.1%	-21.8 [-35.9, -7.7]	65.4%	79.5%	98.7%	64.1%
$T = 0.8$	44.9%	-32.1 [-46.2, -16.7]	56.4%	74.4%	100.0%	56.4%
Human, same topics	76.9%	-	87.2%	91.0%	92.3%	80.8%
Fillers 1 / 2 (human, not endpoints)	83.3 / 79.5%	-	88.5 / 91.0%	98.7 / 93.6%	94.9 / 94.9%	83.3 / 85.9%

Table 2: Judged-bad lines (flagged by at least two of three runs) on the 78 titles, and how many of them carry a flagged span that reaches the line end in a majority of the flagging runs.

Arm	Stanzas with 0/1/2 bad lines	Bad lines on lines 1/2/3/4	Span at line end
$T = 0.4$	67 / 9 / 2	5 / 6 / 2 / 0	9 of 13
$T = 0.6$	51 / 26 / 1	7 / 10 / 5 / 6	19 of 28
$T = 0.8$	44 / 32 / 2	7 / 15 / 8 / 6	19 of 36
Human	68 / 9 / 1	1 / 4 / 3 / 3	6 of 11

by the bias from writing each prompt from its human control (Section 3.3); the fillers, also judged against topics written from themselves (or, for 7 opening-post stanzas, against the thread title they were written to), reach 98.7% and 93.6% alignment. We read this as evidence that the method is level with human verse in this pool on cleanness, and below it on alignment by an amount that the topic-writing procedure may partly or wholly explain.

Ratios. Relative to the all-three rate at $T = 0.4$, the same model and decoder reach 0.782 of it at temperature 0.6 (95% CI [0.652, 0.923]) and 0.636 at 0.8 ([0.489, 0.804]).

Temperature, on the same titles. The same model and decoder at temperature 0.8 pass 44.9%, and at 0.6 55.1%. The step from 0.8 to 0.4 is +25.6 points of all-three ([+12.8, +38.5]; 25 vs. 5 titles, $p = 0.0003$) and +29.5 of cleanness ([+17.9, +41.0]; 26 vs. 3), with alignment +10.3 ([0.0, +20.5]; 12 vs. 4, $p = 0.077$). From 0.6 to 0.4 cleanness still rises on 17 titles against 1. The dose response is monotone in cleanness (56.4, 65.4, 85.9%) and in the number of judged-bad lines (36, 28, 13 of 312).

5.1 Where the remaining errors are

Lowering the temperature mainly removes stanzas with one bad line (32 at 0.8, 9 at 0.4); at 0.4 the distribution of bad lines per stanza matches the human one (67/9/2 against 68/9/1). A line-final flagged span is common in both system and human lines (9 of 13 and 6 of 11), so a span at the line end, where the rhyme syllable sits, is not by itself a signature of the rhyme mask: it may be where this judge locates any phrase that does not hold together.

5.2 Vocabulary and diversity

The cost of the method is plainer and less varied text. Measured on dictionary-segmented tokens, leaving out the topic’s own words, against the 78 human controls, rare words (fewer than 50 training occurrences) are 10.0% of tokens at $T = 0.8$, 8.1% at 0.6 and 7.5% at 0.4, against 16.5% for the human stanzas; very common words (2,000 or more) are 35.2%, 38.2% and 40.8% against 27.9%; distinct word types at a matched budget of 1,516 tokens are 838, 736 and 681 against 939. From 0.8 to 0.4, the ratio of distinct to total syllable bigrams within lines falls from 0.872 to 0.784 (human 0.935), the entropy of line-final syllables from 7.06 to 6.71 bits (human 7.73), repeats of multi-syllable words across lines rise from 0.36 to 0.58 per stanza (human 0.08), and stutters, adjacent identical written syllables, from 0.026 to 0.077 per stanza (human 0.154; the

Table 3: KlonSuphap-LM against the method and human verse on the 78 held-out titles, all in the same new pools, three independent judge runs. The method’s and the human stanzas are the ones of Table 1, judged again in this company.

Arm	All three	Clean	Aligned ≥ 4	Form
The method ($T = 0.4$)	69.2%	85.9%	80.8%	98.7%
KlonSuphap-LM ($T = 0.4$)	0.0%	3.8%	0.0%	19.2%
Human, same topics	75.6%	87.2%	92.3%	92.3%

stutter ban permits attested pairs such as รักรัก). The topic is repeated more: the share of stanzas that use one topic word four or more times rises from 11.5% to 24.4%, and topic words per stanza from 3.9 to 5.1.

5.3 Originality

A generator trained on a forum corpus could reproduce lines it has seen. We compared every line of the 78 held-out stanzas (312 lines) with every line of three corpora: the training and test splits of the forum data (237,872 lines) and a further verse collection that this model was not trained on (369,742 lines: other verse posts of the same forum, the classical epic Phra Aphai Mani and the *klon* pages of Thai Wikisource). No generated line occurs verbatim in any of them, and 152 of the 312 lines share no run of four or more written syllables (PyThaiNLP’s syllable segmentation) with any corpus line. Runs of 8, 6, 5 and 4 syllables are tested; the longest shared run is six or seven syllables, in 10 lines, and the shared runs are common set phrases, most of them from greeting and blessing verse (e.g. ขอให้ความสุขทุกช่วงนาที, ขออำนาจสิ่งศักดิ์สิทธิ์ทั่วสากล); Appendix D lists the 10 lines, each with its shared phrase and one corpus line that contains it. As a check that the test detects copying, the human control stanzas, which belong to the test split, are found verbatim in 153 of their 312 lines; the other 159 differ from their corpus lines only in spacing, because spaces were removed from the controls when they were pooled, and all 312 match once spaces are removed from the corpus lines as well. The generated lines contain no spaces, and none of them matches a corpus line even with spaces removed. The body was pretrained on Thai web text that we cannot search, so this check shows that the stanzas are not copied from the verse corpora above, not that no line exists anywhere. The same check on 100 stanzas written for 20 deliberately unusual topics, which cannot have been seen in training, is in Appendix E.

5.4 Baseline: KlonSuphap-LM

KlonSuphap-LM [33] is a GPT-2 model of 124M parameters released under the MIT licence; we ran the public checkpoint locally on CPU. Its only input is a text prefix, which it continues: the model card’s example passes a short phrase as its input, and the model was trained on poem text alone from classical literature, without topic–poem pairs. We therefore give the topic as the stanza’s opening words, exactly as in the model card. To give it a fair setting, its sampling temperature was chosen before the held-out run on the 49 development topics, with the same judge (one run), among 0.4, 0.6, 0.8 and 1.0 with ten samples per topic (nucleus $p = 0.85$ as in the model card, and the Hugging Face **transformers** default $\text{top-}k$ of 50), by a rule fixed in advance: the highest all-three rate, ties broken by the cleanness rate and then by the lower temperature. It passed all-three on no development stanza at any temperature; cleanness tied at 0.4 and 0.6, and the rule picked 0.4. It then wrote one stanza for each of the 78 held-out titles, judged three times in new pools with the method’s stanzas from Table 1, the human controls and one human filler per title.

KlonSuphap-LM passes all-three on none of the 78 titles (method minus baseline +69.2 points, 95% CI [+59.0, +79.5]; Table 3). Its stanzas fail on every axis: 19.2% pass the form checker (21.8% on syllable counts and the three rhyme links alone), mostly through missing the rhyme from line 1 into line 2 (42 of 78) and the rhyme from line 2 into line 4 (30 of 78); 3.8% are judged clean; none is judged on topic, which its lack of topic conditioning makes partly a property of the comparison rather than of the model. Cleanness (+82.1 points, [+73.1, +91.0]) and form (+79.5, [+70.5, +88.5]) are the fairer contrasts. In this new pool company the method’s and the human stanzas score within 1.3 points of their Table 1 rates on all-three and cleanness; on alignment the method moves from 84.6% to 80.8% and the human stanzas from 91.0% to

92.3%, so re-judging the same stanzas among different neighbours moves a rate by up to 3.8 points. The judge runs agree (Fleiss κ 0.84 for cleanness per line, 0.95 for alignment).

A kinder start. To separate topic following from writing, we also gave KlonSuphap-LM the human control’s first line for each held-out title, with that line’s last syllable in the model’s own rhyme tag, and let it write lines 2–4 (temperature 0.4; cleanness only, three judge runs, Fleiss κ 0.88 for cleanness per line). Its rhyme improves markedly: the line-2-to-line-3 rhyme holds in 88.5% of stanzas and the line-2-to-line-4 link of group B in 62.8% (human 100%), and 24.4% pass the full form checker (1.3% in a second generation run whose prompt omits the rhyme tag). Its language does not: all three of its lines are judged clean in 2.6% of stanzas, and 32.5% of its lines are clean, against 92.3% and 97.4% for the human lines 2–4 of the same stanzas (difference -89.7 points, $[-96.2, -83.3]$). Our method, which was not given the first line, has all of lines 2–4 of its own Table 1 stanzas judged clean in 88.5% of the titles when they are judged again in these first-line-variant pools.

6 Why Low Temperature Works

A stanza has about 32 syllable cells, and it is clean only if all four lines are. A small per-cell probability of an ill-formed choice therefore compounds into a large per-stanza failure rate. If the model’s high-probability choices are mostly well formed and its tail mostly is not, temperature acts on exactly the right part of the distribution: it reweights a token by $p^{1/T}$, so a token with a tenth of the leading token’s probability keeps $0.1^{1.25} \approx 0.056$ of the leader’s weight at $T = 0.8$ but $0.1^{2.5} \approx 0.003$ at $T = 0.4$, about 18 times less. The held-out data fit this account: cleanness rises monotonically as T falls, the gain comes from stanzas with a single bad line, and the vocabulary moves towards common words at the same time (Section 5). The hard masks make this cheap: because rhyme, tone and length are enforced on the sound layer at every temperature, sharpening the distribution cannot break the form (98.7–100% at all three temperatures), and the only thing it trades away is lexical variety.

Sampling or decoder bonuses? The decoder adds a topic bonus and subtracts a repetition penalty from the logits before dividing by T , so at $T = 0.4$ these terms act twice as strongly as at 0.8. A pre-registered development test separated the two effects on the 49 development topics with ten samples each (one judge run, so these are development numbers): at $T = 0.4$ with both terms scaled down to their 0.8 strength (the rescaling applies only to the draw; the choice of cell, the rime family and the top-512 cut use the unscaled scores, as in every arm), all-three was 77.3% against 78.6% with them at full strength and 63.3% at $T = 0.8$, so the sharper sampling alone keeps 0.92 of the gain (95% CI $[0.76, 1.13]$). The mirror arm, $T = 0.8$ with the terms doubled, recovers only 0.21 of it ($[-0.07, 0.49]$), though about half of the alignment gain. The all-three gain is therefore a property of sampling the model’s own distribution more sharply.

Three limits of this account are known. (i) The gain is bought with vocabulary and diversity, measured above. (ii) Part of the alignment gain may be topic echo, which the alignment instrument does not penalise: topic words per stanza rise from 3.9 to 5.1 between 0.8 and 0.4. (iii) The rime family is chosen at a fixed family temperature of 0.5 that the sampling temperature does not reach, and this choice over-produces one rime family: on the 78 held-out stanzas at $T = 0.4$, the merged *ai* family (1/1/-๕๒ ~ -๗๒, Section 3.1) carries 41.0% of the rhyme-group rimes (the ends of lines 1 and 2), against 10.9% in the human controls. Temperatures below 0.4 were not evaluated.

7 Limitations

Sample size. The evaluation has 78 titles, so intervals on rates are about ± 10 points and the interval of the difference to human runs from -19.2 to $+6.4$ points. The temperature 0.4 was chosen from development results on the same model and judge; it was fixed as the primary arm before the held-out titles were decoded.

Plainer vocabulary. The method’s Thai is measurably plainer than the human stanzas’: fewer rare words, more very common ones, fewer distinct types, more repetition of content words and of the topic (Section 5).

The cleanness and alignment instruments do not penalise this, and alignment may reward topic echo. The evaluation does not measure literary quality, imagery or originality.

The human control and its topics. All 78 prompts were written by Claude Opus 5.5, the model that also serves as judge, from the human control stanza, which favours the human arm on alignment; the human controls are reply stanzas from threads whose own titles were unusable as prompts, not a random sample of the forum, and they are amateur verse, 12.8% of whose stanzas carry a judged-bad line. The model was trained on thread titles, which are not summaries of the stanza, so the prompts differ in kind from its training topics.

LLM judging. Every cleanness and alignment rate is a rate under one LLM judge family, validated against human anchor stanzas and three independent runs. An LLM judge and a human reader do not flag the same lines: in a blind check of 30 stanzas from the second of the two earlier held-out evaluations (Introduction), the author marked at least one unacceptable line in 11 of the 15 system stanzas the judge called unclean, in 7 of the 8 system stanzas the judge called clean and in 4 of the 7 human stanzas (judge: 1 of 7); over the 120 lines, both flagged 6, only the author 16 and only the judge 12. No such reader check exists for the evaluation reported here.

Judging in one context per run. The protocol specified a separate judge session (a fresh agent conversation) for each pool and run. The stored verdicts show that each of the three runs instead judged all six pools in a single session: within a run, the 16 anchors received identical verdicts in all six cleanness pools and word-for-word identical alignment theses in all six alignment pools, and the alignment files of runs 1 and 3 were each written at a single time. The three runs remain independent of each other, which is what the majority and median rules and the kappa need; but the anchor check is in effect one check per run rather than six, and a judge drifting between pools within a run would not be detected by it.

The baseline. KlonSuphap-LM receives the topic only as its opening words and was trained on classical verse, so the comparison on alignment is not like for like; we tuned its temperature and also report a kinder setting that gives it the human first line, but did not retrain it.

Scope. One generator family, one forum corpus, one-stanza outputs, one judge family, amateur forum verse as the human bar.

Reproducibility. Decoding is deterministic given the weights, the seed and the decode command: a single script re-decodes the 78 held-out stanzas byte for byte from the released checkpoint (sha256 in Appendix A), on the Apple-silicon GPU and on CPU, and re-scores the held-out evaluation, the baseline comparisons and the confound test from the stored judge verdicts, which reproduce exactly; the analysis scripts of Appendix A recompute the remaining numbers from the same files. Training is not bit-deterministic on that GPU, so retraining from the released script, log and data gives a similar rather than identical model. The judge is the part that cannot be reproduced exactly. Cleanness and alignment were judged by Claude Opus 5.5, run as agents with frozen, published prompts; all raw verdicts are released. Asking the judge again is stochastic: the three independent runs agreed with Fleiss κ 0.76 for cleanness per line and 0.84 for alignment in the main evaluation, 0.84 and 0.95 in the KlonSuphap-LM comparison, and 0.88 for cleanness in the first-line variant, so a re-judging should fall within that run-to-run variation rather than match exactly, and a different or updated judge model may move absolute rates. For this reason every comparison is made within the same pools, which also contain human anchors whose rates are reported. The forum verse used for training and as the human control is not redistributed; we release thread, post and stanza identifiers with which the corpus can be rebuilt.

8 Ethics and Broader Impact

The corpus is publicly posted member verse, crawled for research; stanzas are not redistributed beyond short examples. The Claude-written topics are summaries of public stanzas. Generated verse could be passed off

as a person’s own work; a release should state machine authorship. The judge was never used as a training reward. No personal data beyond public forum posts was processed, and no human-subjects study was conducted beyond the author’s own reading.

9 Conclusion

A single sample at temperature 0.4 from a two-layer sound–word canvas model writes *klon pad* stanzas that, on 78 held-out titles judged three times, pass form, cleanness and alignment together on 70.5% of titles against 76.9% for human verse on the same topics. Cleanness is level with human; the remaining difference is alignment on topics written from the human stanzas. Keeping words whole while enforcing rhyme, tone and length on pronounced syllables makes form a property of the decoder, and sampling at a low temperature removes most lexical errors, which sit in the model’s low-probability choices; the price is a plainer vocabulary. A model whose low-probability choices are worth sampling is the open problem.

References

- [1] Wirote Aroonmanakun. TLTK: Thai language toolkit. Python package, version 1.11, <https://pypi.org/project/tltk/>.
- [2] Jacob Austin, Daniel D. Johnson, Jonathan Ho, Daniel Tarlow, and Rianne van den Berg. Structured denoising diffusion models in discrete state-spaces. In *35th Conference on Neural Information Processing Systems (NeurIPS 2021)*, 2021.
- [3] Tuhin Chakrabarty, Philippe Laban, Divyansh Agarwal, Smaranda Muresan, and Chien-Sheng Wu. Art or artifice? large language models and the false promise of creativity. In *Proceedings of the CHI Conference on Human Factors in Computing Systems (CHI ’24)*. ACM, 2024. URL <https://arxiv.org/abs/2309.14556>.
- [4] Huiwen Chang, Han Zhang, Lu Jiang, Ce Liu, and William T. Freeman. MaskGIT: Masked generative image transformer. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11315–11325, 2022. doi: 10.1109/CVPR52688.2022.01103.
- [5] Cheng-Han Chiang and Hung-yi Lee. Can large language models be an alternative to human evaluation? In Anna Rogers, Jordan Boyd-Graber, and Naoaki Okazaki, editors, *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 15607–15631, Toronto, Canada, July 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.acl-long.870. URL <https://aclanthology.org/2023.acl-long.870/>.
- [6] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems, 2021. URL <https://arxiv.org/abs/2110.14168>.
- [7] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.
- [8] Marjan Ghazvininejad, Xing Shi, Yejin Choi, and Kevin Knight. Generating topical poetry. In *Proceedings of EMNLP*, pages 1183–1191, 2016.
- [9] Marjan Ghazvininejad, Xing Shi, Jay Priyadarshi, and Kevin Knight. Hafez: an interactive poetry generation system. In Mohit Bansal and Heng Ji, editors, *Proceedings of ACL 2017, System Demonstrations*, pages 43–48, Vancouver, Canada, July 2017. Association for Computational Linguistics. URL <https://aclanthology.org/P17-4008/>.
- [10] Marjan Ghazvininejad, Omer Levy, Yinhan Liu, and Luke Zettlemoyer. Mask-predict: Parallel decoding of conditional masked language models. In *Proceedings of EMNLP-IJCNLP*, pages 6112–6121, 2019.
- [11] Chris Hokamp and Qun Liu. Lexically constrained decoding for sequence generation using grid beam search. In Regina Barzilay and Min-Yen Kan, editors, *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 1535–1546, Vancouver, Canada, July 2017. Association for Computational Linguistics. doi: 10.18653/v1/P17-1141. URL <https://aclanthology.org/P17-1141/>.

- [12] Ari Holtzman, Jan Buys, Li Du, Maxwell Forbes, and Yejin Choi. The curious case of neural text degeneration. In *International Conference on Learning Representations (ICLR)*, 2020.
- [13] Zhiyuan Hu, Chumin Liu, Yue Feng, Anh Tuan Luu, and Bryan Hooi. Poetrydiffusion: Towards joint semantic and metrical manipulation in poetry generation. In *The Thirty-Eighth AAAI Conference on Artificial Intelligence (AAAI-24)*, pages 18279–18288. Association for the Advancement of Artificial Intelligence, 2024.
- [14] Chihan Huang and Xiaobo Shen. Poembert: A dynamic masking content and ratio based semantic language model for chinese poem generation. In *Proceedings of the 31st International Conference on Computational Linguistics*, pages 50–60. Association for Computational Linguistics, 2025. January 19-24, 2025.
- [15] Manoj Balaji Jagadeeshan, Samarth Bhatia, Pretam Ray, Harshul Raj Surana, Akhil Rajeev P, Priya Mishra, Annarao Kulkarni, Ganesh Ramakrishnan, Prathosh AP, and Pawan Goyal. Chandomitra: Towards generating structured Sanskrit poetry from natural language inputs, 2025. URL <https://arxiv.org/abs/2506.00815>.
- [16] Tom Kocmi and Christian Federmann. GEMBA-MQM: Detecting translation quality error spans with GPT-4. In *Proceedings of the Eighth Conference on Machine Translation (WMT)*, pages 768–775, 2023.
- [17] Jey Han Lau, Trevor Cohn, Timothy Baldwin, Julian Brooke, and Adam Hammond. Deep-speare: A joint neural model of poetic language, meter and rhyme. In *Proceedings of ACL*, pages 1948–1958, 2018.
- [18] Piji Li, Haisong Zhang, Xiaojiang Liu, and Shuming Shi. Rigid formats controlled text generation. In Dan Jurafsky, Joyce Chai, Natalie Schluter, and Joel Tetreault, editors, *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 742–751, Online, July 2020. Association for Computational Linguistics. doi: 10.18653/v1/2020.acl-main.68. URL <https://aclanthology.org/2020.acl-main.68/>.
- [19] Lalita Lowphansirikul, Charin Polpanumas, Nawat Jantrakulchai, and Sarana Nutanong. WangchanBERTa: Pretraining transformer-based Thai language models. *arXiv preprint arXiv:2101.09635*, 2021.
- [20] Ximing Lu, Peter West, Rowan Zellers, Ronan Le Bras, Chandra Bhagavatula, and Yejin Choi. NeuroLogic decoding: (un)supervised neural text generation with predicate logic constraints. In Kristina Toutanova, Anna Rumshisky, Luke Zettlemoyer, Dilek Hakkani-Tur, Iz Beltagy, Steven Bethard, Ryan Cotterell, Tanmoy Chakraborty, and Yichao Zhou, editors, *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 4288–4299, Online, June 2021. Association for Computational Linguistics. doi: 10.18653/v1/2021.naacl-main.339. URL <https://aclanthology.org/2021.naacl-main.339/>.
- [21] Max Peeperkorn, Tom Kouwenhoven, Dan Brown, and Anna Jordanous. Is temperature the creativity parameter of large language models? In *Proceedings of the 15th International Conference on Computational Creativity (ICCC’24)*, 2024. URL <https://arxiv.org/abs/2405.00492>.
- [22] Wannaphong Phatthiyaphaibun, Korakot Chaovavanich, Charin Polpanumas, Arthit Suriyawongkul, Lalita Lowphansirikul, Pattarawat Chormai, Peerat Limkonchotiwat, Thanathip Suntornitip, and Can Udomcharoenchaikit. PyThaiNLP: Thai natural language processing in python. In Liling Tan, Dmitrijs Milajevs, Geeticka Chauhan, Jeremy Gwinnup, and Elijah Rippeth, editors, *Proceedings of the 3rd Workshop for Natural Language Processing Open Source Software (NLP-OSS 2023)*, pages 25–36, Singapore, December 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.nlposs-1.4. URL <https://aclanthology.org/2023.nlposs-1.4/>.
- [23] Wannaphong Phatthiyaphaibun, Korakot Chaovavanich, Charin Polpanumas, Arthit Suriyawongkul, Lalita Lowphansirikul, and Pattarawat Chormai. PyThaiNLP: Thai natural language processing in Python. Zenodo, software version v5.0.4, <https://github.com/PyThaiNLP/pythainlp/>, June 2024.
- [24] Nuttachot Promrit, Sajjaporn Waijanya, and Kran Thaweessith. The evaluation of Thai poem’s content consistency using Siamese network. In *Proceedings of the 2019 3rd International Conference on Natural Language Processing and Information Retrieval (NLPPIR)*, pages 115–120. ACM, 2019. doi: 10.1145/3342827.3342855.
- [25] PyThaiNLP. klongklon. Hugging Face dataset, <https://huggingface.co/datasets/pythainlp/klongklon>, 2023. URL <https://huggingface.co/datasets/pythainlp/klongklon>. Accessed 2026-10-03.

- [26] Subham Sekhar Sahoo, Marianne Arriola, Yair Schiff, Aaron Gokaslan, Edgar Marroquin, Justin T Chiu, Alexander Rush, and Volodymyr Kuleshov. Simple and effective masked diffusion language models. In *38th Conference on Neural Information Processing Systems (NeurIPS 2024)*, 2024.
- [27] Jitkapat Sawatphol. Thai Literature Corpora. <https://github.com/jitkapat/thailitcorpus>, 2019. URL <https://attapol.github.io/tlc.html>. Version 2.0.
- [28] Yan Song. Composing ci with reinforced non-autoregressive text generation. In *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, pages 7219–7229. Association for Computational Linguistics, 2022. December 7-11, 2022.
- [29] Yufei Tian and Nanyun Peng. Zero-shot sonnet generation with discourse-level planning and aesthetics features. In Marine Carpuat, Marie-Catherine de Marneffe, and Ivan Vladimir Meza Ruiz, editors, *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 3587–3597, Seattle, United States, July 2022. Association for Computational Linguistics. doi: 10.18653/v1/2022.naacl-main.262. URL <https://aclanthology.org/2022.naacl-main.262/>.
- [30] Tuul Triyason. Lilit to ramakien: A five-work benchmark for LLM understanding of classical Thai literature. In *Proceedings of the 14th International Conference on Advances in Information Technology*, pages 1–9. ACM, 2026. doi: 10.1145/3816713.3816760.
- [31] Alex Wang and Kyunghyun Cho. BERT has a mouth, and it must speak: BERT as a Markov random field language model. In Antoine Bosselut, Asli Celikyilmaz, Marjan Ghazvininejad, Srinivasan Iyer, Urvashi Khandelwal, Hannah Rashkin, and Thomas Wolf, editors, *Proceedings of the Workshop on Methods for Optimizing and Evaluating Neural Language Generation*, pages 30–36, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi: 10.18653/v1/W19-2304. URL <https://aclanthology.org/W19-2304/>.
- [32] Lanqing Xue, Kaitao Song, Duocai Wu, Xu Tan, Nevin L. Zhang, Tao Qin, Wei-Qiang Zhang, and Tie-Yan Liu. DeepRapper: Neural rap generation with rhyme and rhythm modeling. In *Proceedings of ACL-IJCNLP*, pages 69–81, 2021.
- [33] Kampanat Yingseree. KlonSuphap-LM or GPT-2 for Thai poems (Klon-Paed poem). Hugging Face model card, <https://huggingface.co/Kongfha/KlonSuphap-LM>; code at <https://github.com/Kongfha/KlonSuphap-LM>, 2023. URL <https://huggingface.co/Kongfha/KlonSuphap-LM>. Accessed 2026-10-03.
- [34] Nutchanon Yongsatianchot and Phuvis Kerdpramote. Composing within constraints: A benchmark for Thai classical poetry in large language models. In *Proceedings of the 2026 Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the International Joint Conference on Natural Language Processing (AACL-IJCNLP 2026)*, 2026. URL <https://github.com/yongsa-nut/ThaiProsody>.
- [35] Xingxing Zhang and Mirella Lapata. Chinese poetry generation with recurrent neural networks. In *Proceedings of EMNLP*, pages 670–680, 2014.
- [36] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, and Ion Stoica. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. In *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2023.

A Reproduction

The code, the checkpoint, the pre-registrations and the raw judge verdicts are available from the author. Paths are relative to the repository root. The folder and file names are internal names, kept so that the commands run as printed (suffixes such as `v4bot`, `rev3`, `revision1` and `new2` are historical version labels); each is explained here. Commands use the project’s Python environment (`.venv/bin/python`).

- `runs/TLLONG/model_h24`: the released checkpoint, the 24-epoch model of Section 4, with its training log `train.log`; the weights `model.pt` have sha256 `53ef5c171d9bda7dc0b93a2c40cd842f2d5837467c77963f7cfc64cd19f6bcbe`. `runs/TLLONG/allow.json` is the stutter-ban allowlist.

- `runs/CONFIRM3`: the held-out evaluation. `S04`, `S06` and `S08` hold the stanzas decoded at $T = 0.4$, 0.6 and 0.8 (`c0.jsonl`); `SCORE.json`, `STATS.json` and `VOCAB.json` hold the scores and read-outs; `FREEZE.txt` records, before decoding, the code commit (`a6d41f0`), the model hash and the hashes of the prompts, human controls and fillers; `ORIGINALITY.json` and `ORIGINALITY_HUMAN.json` hold the originality checks.
- `runs/C3J_CLEAN00` to `runs/C3J_CLEAN05` and `runs/C3J_ALIGN00` to `runs/C3J_ALIGN05`: the six cleanliness and six alignment pools of the held-out evaluation. Each holds the batch files given to the judge, the key map and the three independent judge runs `run1.json`, `run2.json`, `run3.json`.
- `runs/KSPBASE`: the KlonSuphap-LM comparison (its development temperature sweep in `sweep`); its four cleanliness and four alignment pools are `runs/KSJ_CLEAN00-03` and `runs/KSJ_ALIGN00-03`. `runs/KSPW1`: the first-line variant (“a kinder start”), with pools `runs/KSK_CLEAN00-03`. `runs/TEMPCONF`: the development confound test of Section 6.
- `runs/CSEL/CONFIRM3_PREREG.md`, `KLONSUPHAP_BASELINE_PREREG.md` and `TEMP_CONFOUND_PREREG.md`: the pre-registrations of the held-out evaluation, the baseline comparison and the confound test.
- `docs/judge_v4bot_prompt.txt`, `docs/judge_align_bot_prompt.txt` and `docs/judge_wrapper_v1.md`: the cleanliness prompt, the alignment prompt and the agent instruction (Appendix B). `klon8/prosody.py` is the form checker.

One command runs every check (input hashes, byte-identical re-decoding of the 78 stanzas, a CPU-against-GPU check on three titles, and re-scoring of the evaluation, the baseline comparisons and the confound test from the stored verdicts):

```
zsh reproduce.sh
```

The decoding command of the method is

```
.venv/bin/python scripts/twolayer_templow.py decode \
--model runs/TLLONG/model_h24 --unit syllable --stutter-fix \
--allow runs/TLLONG/allow.json --topic-clear \
--prompts data/prompts/confirm3.jsonl --seed 0 --temp 0.4 \
--out S04_c0.jsonl
```

Here `--unit syllable` makes one cell per pronounced syllable, `--stutter-fix` with `--allow` turns on the stutter ban and its allowlist, and `--topic-clear` clears the topic bonus in a line once a topic word is completed there (Section 4.2). (`reproduce.sh` sets `KLON8_G2P_CACHE` to a copy of `runs/TLLONG/g2p_cache.json` so that the shared pronunciation cache is not modified). The held-out scores and the KlonSuphap-LM scores are recomputed by

```
.venv/bin/python scripts/confirm3.py score runs/CONFIRM3
.venv/bin/python scripts/klonsuphap_c3.py score runs/KSPBASE
```

which rewrite the stored `SCORE.json` (`reproduce.sh` works on copies instead). `docs/paper_best/confirm3_analysis.py` prints the discordant counts, ratios and Table 2; `scripts/originality_check.py` reproduces Section 5.3; `docs/paper_best/revision1_checks.py` prints the line-length shares, the rime-family shares, the human diversity values, the held-out selection counts and the filler origins; `docs/paper_best/make_appendix.py` generates Appendix C; `docs/paper_best/originality_examples.py` finds the shared phrases and example corpus lines of Appendices D and E, and `docs/paper_best/make_appendix_rev3.py` typesets both appendices; the stanzas for unusual topics are in `runs/ORIGINALITY20` (written by the repository’s command-line generator, `KLON8_DEVICE=cpu ./poem -n 5 --json` with the topics on one command line; with topics on the command line each topic’s stanzas depend only on the topic and the seed, so the topics may be decoded in any grouping).

B Judge prompts

Both prompts are reproduced verbatim as they were given to the judge. Each batch file given to the judge begins with the prompt, followed by the items.

Cleanness prompt.

You are an annotator for the lexical quality of Thai กลอนแปด verse. Identify exact error spans and classify them.

This is poetry, not everyday prose. Do not mark abstraction, metaphor, personification, archaic or poetic diction, unusual imagery, or natural poetic compounds as errors. Do not judge rhyme, syllable count, or verse structure.

Mark as an error any exact span that is not linguistically well formed in Thai, such as a non-word, an unrecognizable misspelling, an unnatural word formation, an unnatural combination of words that disrupts reading. Classify as: 1) ****critical**** if the error makes the **วรรค** incomprehensible. 2) ****major**** if it makes a native reader stumble but the **วรรค** remains understandable. Or, it contains a non-word unless that non-word is a genuine Thai prefix or suffix that can attach to the neighbouring word 3) ****pass**** if it is technically erroneous but does not disrupt reading. 4) ****pass**** if there is no error.

Input: each item has a key, a topic, and 4 numbered lines. Output one JSON array with one object per item, in order: {"item": "<key>", "errors": [{"line": <1-4>, "span": "<exact substring of that line>", "severity": "critical|major"}, ...]}. If there is no error, "errors" is [] (pass).

Alignment prompt.

You are judging whether a Thai กลอนแปด poem is about the topic it was given. Read the topic and the 4 lines.

First write, in one Thai sentence, what the poem is actually about. Then compare that with the topic and score how much of the poem stays on the topic.

Judge subject matter only. Ignore rhyme, syllable count, verse structure, spelling, and the quality of the wording. A poem may treat its topic figuratively, through imagery or metaphor, and is still on the topic.

Score 1 to 5: 5 = every **วรรค** is on the topic. 4 = the poem is on the topic, with at most one **วรรค** that wanders. 3 = partly on the topic. 2 = the topic is touched once and then left. 1 = unrelated to the topic.

Input: each item has a key, a topic, and 4 numbered lines. Output one JSON array with one object per item, in order: {"item": "<key>", "thesis": "<one Thai sentence>", "align": <1-5>}. Nothing else.

Agent instruction. Each run of an instrument was given to the judge as an agent with a fixed instruction (released with the prompts); as Section 7 reports, one conversation per run judged all six pools. The instruction tells the agent to read every batch file of a pool, to follow the prompt at the head of each file exactly as written without adding, relaxing or tightening criteria, and to return a result for every item under its random key. As part of the instrument it states that the pool deliberately mixes system-generated and human-written poems, unlabelled, to be judged by the same standard without guessing which is which; that the topics are everyday subjects to be judged as given; and, for cleanness, it restates the exemption for metaphor, personification, archaic or poetic diction and unusual imagery and the critical/major definitions. The agent may read only the batch files, never the key map or any earlier run, and writes its verdicts to a JSON file whose item set it checks against the batches.

C Generated stanzas that pass all three tests

The first 30 titles, in order of title id (read each column from top to bottom), among the 55 whose stanza at $T = 0.4$ passes form, cleanness and alignment in the held-out evaluation. Each entry gives the title id, the topic (the prompt) and the four lines exactly as generated (one sample, seed 0, no selection or editing).

K001 เชิดชูทหาร

ขอเชิดชูเหล่าทหารที่ยิ่งใหญ่
ทำงานหนักด้วยใจใฝ่ฝึกฝน
เสียสละชีวิตอย่างอดทน
เพื่อเป็นคนหาญกล้าของแผ่นดิน

K003 น้ำใจนำสรรเสริญ

อันน้ำใจงดงามและยิ่งใหญ่
คือพลังน้ำใจที่สร้างสรรค์
น้ำใจดีมีน้ำใจมีแบ่งปัน
ช่วยเหลือกันทุกวันน่าชื่นชม

K005 ดกหลุมพรางเพราะเปลือก

เพราะแค่เปลือกที่เราเห็นในความคิด
จึงหมดสิทธิ์ที่จะคิดและหลงใหล
รักเพราะเปลือกแต่ข้างในคือใจใคร
สุดท้ายไปไม่อาจรู้ซึ่งความจริง

K006 ชินเจียอยู่ขอให้อยู่

ชินเจียอยู่ขอให้อยู่
ชินเจียอยู่ขอให้อยู่
ทุกคืนเข้าคืนวันพลันสดใส
ขอให้สหายและรายทรัพยากรนั้นมากมาย
ขอให้กายสุขใจในทุกวัน

K007 เก็บเดือนดาวไว้ในใจ

เก็บเดือนดาวพราวไว้ในใจใคร
เก็บเดือนดาวเอาไว้ใจไหนดวง
เก็บเดือนดาวแนบไว้ในดวงดวง
เก็บทุกช่วงดวงใจมอบให้เธอ

K009 ขอหมอนกับผ้าห่ม

นอนกับหมอนผ้าห่มให้อุ่น
อุ่นละมุนหนุนตักอยู่ไม่รู้หาย
ยังคิดถึงคนดีคนข้างกาย
หลับสบายอุ่นใจยามกอดเธอ

K010 ใส่บาตรปีใหม่ไทย

ร่วมใส่บาตรปีใหม่ไทยทั่วหล้า
ร่วมตักบาตรเข้ามาพาสุขสันต์
ได้ทำบุญอุทิศไปให้แก่กัน
เนื่องในวันปีใหม่ไทยเทอญ

K011 หลงมนต์กลอน

หลงอักษรกลอนภาษารัก
หลงประจักษ์วาจาพาหลงไหล
หลงเสน่ห์มนต์รักปักทรวงใน
หลงฤทธิ์ใฝ่ป้องในน้องนาง

K014 ปู่จับปลามาเหน้อย

ฉันจับปลามาเหน้อยและล้านัก
จึงขอพักสักครู่ก็พอไหว
อยากจับปลามาพักเพื่อผ่อนคลาย
แต่ทำไมไม่จับปลามาเสียที

K015 จำใจจากเพราะจน

จำต้องจากเพราะจนอนาถนัก
ไม่มีรักจริงใจเหมือนในฝัน
เคยร่วมเรียงเคียงกายใจใกล้กัน
ทุกคืนวันฝันผ่านทรมาน

K017 วอนเทพประสาทพร

วอนเทพไทเทวาสั่งศักดิ์สิทธิ์
เนรมิตดลจิตนิมิตฝัน
จงสดชื่นรื่นชื่นชื่นชื่น
ทุกคืนวันสุขสันต์วันรื่น

K018 เพื่อนข้างกาย

เพื่อนที่อยู่ข้างกายมีทางหาย
เพื่อนที่คอยห่วงใยไม่เคยห่าง
เพื่อนที่รักจริงใจไม่จืดจาง
เพื่อนที่อยู่เคียงข้างอย่างจริงจัง

K019 ให้ความเศร้าผ่านพ้นไป

ปล่อยความเศร้าผ่านไปในชีวิต
อย่ายึดติดโกรธกันจนหวนไหว
ใช้เวลาเยียวยารักษาใจ
ตั้งสติรับไว้ให้ดี

K023 คนชื่อดาว

คนชื่อดาวมีน้ำใจจะคลายหนาว
นภาฝนมีดาวสกาไส
ขอให้ดาวสุกสันต์ฝันทุกวันไป
ฝากดวงดาวหัวใจให้น้องดาว

K026 ขอให้โชคมีชัย

ให้โชคมีชัยมีชัยเกิด
สิ่งประเสริฐจงบังเกิดความสุขใส
อายุมั่นขวัญยืนยังยืนไป
คิดสิ่งใดสมใจทุกสิ่งเทอญ

K027 สุขภาพดีบึง

อายุยืนกว่าใครให้สุขสันต์
อายุนานทุกวันอย่าหวนไหว
สุขภาพดีบึงมันตลอดไป
อายุใจร่างกายยังแข็งแรง

K029 ฟ้าจะไปไกลแล้ว

เธอจะไปไกลแล้วจากใจพี่
โปรดหันมาคนดีที่ห่วงหา
หากมันใจระยะทางอย่าร้างลา
จงกลับมาพบกันในสักวัน

K030 ขอให้มีเวทมนตร์ปาสุ่ม

ขอให้มีเวทมนตร์ปาสุ่ม
ในคืนที่มีจันทร์อันสดใส
จงสนุกสุขสันต์ทุกวันไป
สี่ห้องใจของขวัญให้แต่เธอ

D Shared phrases in the held-out stanzas

Table 4 lists the 10 lines of the 78 held-out stanzas (Section 5.3) whose longest run of written syllables shared with a line of the three corpora is six or more syllables (one of them shares seven). For each, it gives the shared phrase and one corpus line that contains it; the corpus column names the training split (forum train), the test split (forum test) or the further verse collection (further verse). No generated line occurs verbatim in the corpora. The shared phrases are common set phrases, most of them from greeting and blessing verse.

Table 4: The 10 lines of the 78 held-out stanzas ($T = 0.4$) whose longest run of written syllables shared with a corpus line is six or more syllables. Run: length of the longest shared run in syllables. Example corpus line: the first line in corpus order that contains the shared phrase.

Generated line	Run	Shared phrase	Example corpus line	Corpus
ขอให้กายสุขใจในทุกวัน	6	กายสุขใจในทุกวัน	สุขกายสุขใจในทุกวัน และเป็นมิ่งขวัญ ของคนบ้านกลอน	further verse
เนื่องในวันปีใหม่ไทยเทอญ	6	เนื่องในวันปีใหม่ไทย	ขออวยพรเนื่องในวันปีใหม่ไทยให้กับ ท่านอาวุโส	further verse
ขออำนาจสิ่งศักดิ์สิทธิ์ทั่วสากล	6	ขออำนาจสิ่งศักดิ์สิทธิ์	ขออำนาจสิ่งศักดิ์สิทธิ์สถิตฟ้า	forum train
แต่วันนี้ต้องพรากจากแสนไกล	6	แต่วันนี้ต้องพรากจาก	แต่วันนี้ต้องพรากจากเพื่อนแล้ว	further verse
รื่นเริงรมย์ชมชื่นทุกคืนวัน	7	ภิรมย์ชมชื่นทุกคืนวัน	ได้ภิรมย์ชมชื่นทุกคืนวัน	forum train
ขอให้มีความสุขทุกช่วงนาที่	6	ขอให้มีความสุขทุก	ขอให้มีความสุขทุกวัน	forum train
แม่อีกกำลังใจให้ทุกคน	6	กำลังใจให้ทุกคน	เรื่องร้ายให้ผ่านไป เป็นกำลังใจให้ทุก คน	further verse
ขอให้เธอมีความสุขทุกเวลา	6	ขอให้เธอมีความสุข	ขอให้เธอมีความสุข	further verse
หรือหายไปไกลกลับไม่กลับคืน	6	หายไปไกลกลับไม่กลับ	เห็นหายไปไกลกลับไม่กลับเขื่อน	forum train
ขอให้เธอสมหวังตั้งใจใฝ่หม	6	ขอให้เธอสมหวังตั้งใจ	ก็ขอให้เธอสมหวังตั้งใจ	forum test

E Originality on unusual topics

A topic that no training stanza could have been about asks the generator for lines it cannot have seen. In the spirit of the “astronaut riding a horse” prompt used to show what text-to-image generators can compose, 20 deliberately unusual topics were written, such as an astronaut riding an elephant to a floating market. None of them occurs as a training or test title or topic, checked by exact and substring match; the only substring matches are ordinary words and phrases (คิดถึงบ้าน, “homesick”, and แต่งกลอน, “to write verse”). The method wrote five stanzas for each topic (seeds 0–4, $T = 0.4$, decoded on CPU), with no selection or editing; they are shown below, each topic with an English gloss. 99 of the 100 stanzas pass the form checker; the one that fails (marked †, topic 10, seed 3) repeats a rhyme word. These stanzas were not judged for cleanness or alignment.

The originality check of Section 5.3, run on these 100 stanzas (400 lines) against the same three corpora, finds no line verbatim in any of them. The longest run of written syllables shared with a corpus line is 0 (no run of four or more) for 236 lines, 4 for 120, 5 for 39 and 6 or more for 5. Table 5 lists those 5 lines with their shared phrases; as in the held-out stanzas, they are mostly set phrases of birthday, blessing and thanks verse.

Table 5: The 5 lines of the 100 stanzas for unusual topics whose longest run of written syllables shared with a corpus line is six or more syllables, with the shared phrase and the first corpus line that contains it.

Generated line	Run	Shared phrase	Example corpus line	Corpus
ในเวลาคล้ายวันเกิดประเสริฐศรี	6	คล้ายวันเกิดประเสริฐศรี	อายุครบคล้ายวันเกิดประเสริฐศรี	forum train
ขอให้มีความสุขทุกคืนวัน	6	มีความสุขทุกคืนวัน	ครอบครัวมีความสุขทุกคืนวัน	forum train
วันเวลาผ่านไปไม่ต่างกัน	6	วันเวลาผ่านไปไม่	วันเวลาผ่านไปไม่เหมือนเก่า	forum train
ขอขอบคุณน้ำใจที่มาให้	6	ขอขอบคุณน้ำใจที่	ขอขอบคุณน้ำใจที่ได้มา	forum train
ขอขอบคุณมิตรที่มีมา	7	ขอขอบคุณมิตรที่มี	ขอขอบคุณมิตรที่มีให้	forum train

Below, each stanza is labelled with its seed (0–4).

1. นักบินอวกาศขี่ช้างไปตลาดน้ำ (an astronaut rides an elephant to the floating market)
 - 0 อวกาศเรือขี่ช้างไปถึงฝั่ง
หัวใจพังดับสับไม่กลับได้
เหลือเพียงฉันท่านั้นที่ฝันไป
เธออยู่แค่ในใจไม่มีเรา
 - 1 อวกาศขี่ช้างไปกลางป่า
แต่ทว่ายังหาซึ่งจุดหมายได้
ด้วยชะตาชะตาทางอันยาวไกล
คงไม่เป็นตั้งใจในสักวัน
 - 2 อวกาศจะขี่ช้างไปโลกกว้าง
ระยะทางไกลลิบอย่าหวั่นไหว
เพื่อเดินทางสู่ฝันอันยาวไกล
แต่ตัวเธอหายไปใจคนคอย
 - 3 อวกาศขี่ช้างไปเมืองน้อง
ที่พันทองใจดำทำใจ
ระยะทางชายแดนอีกยาวไกล
เครื่องบินน้อยขึ้นไปไม่ปลอดภัย
 - 4 อวกาศขี่ช้างไปใบป่า
เจอคนหล่อโผล่มาว่าเป็นผี
เธอก็ชอบขี้มั่วดูเทดี
แต่ไม่มีใครเห็นหน้าเห็นใจ
2. หุ่นยนต์ตำส้มตำ (a robot pounds papaya salad)
 - 0 เหมือนหุ่นยนต์ตำส้มตำที่เธอสั่ง
ฉันทิ้งส้มตำน้ำตาไหล
ความผิดหวังผิดหวังทุกครั้งไป
เธอต้องการอะไรให้บอกมา
 - 1 หุ่นยนต์ตำส้มตำได้ตั้งว่า
บริการสั่งมาสนุกสนาน
มีลูกค้าประจำร้านแสนสำราญ
บริการรวดเร็วประทับใจ
 - 2 มีหุ่นยนต์ตำส้มตำให้ฉันบ้าง
แต่ละอย่างยากลำบากนำมาใส่
เรียกลูกค้าสั่งกันทุกวันไป
ต้นทุนส่งเท่าไรไม่เคยพอ
 - 3 หุ่นยนต์ตำส้มตำนำมาใส่
แล้วเก็บกล่องเอาไว้ให้ค้นหา
ชื่อเมนูเขาสั่งที่สั่งมา
อยากรู้อย่างไรไม่เข้าใจ
 - 4 หุ่นยนต์ตำส้มตำฉันไม่ว่า
แต่อย่าให้ชื่อมาได้ไหมนี่
เพราะส้มตำครกนั้นมันไม่ดี
ขอคนที่ชำนาญช่วยตำที่
3. ปลาทองเรียนว่ายน้ำออนไลน์ (a goldfish takes swimming lessons online)
 - 0 น่องพันทองเรียนว่ายน้ำออนไลน์ได้
เพียงไม่ต้องตั้งใจหมั่นฝึกฝน
อยากว่ายน้ำให้คล่องต้องอดทน
จะเป็นคนเก่งกล้ากว่าใครใคร
 - 1 เมื่อได้รับคำตอบจากสายตา
จึงรู้ว่าความรู้นั้นหาไม่ได้
ปล่อยให้ปลาเรียนว่ายน้ำออนไลน์ไป
จะเรียนรู้อะไรไม่มีเลย

- 2 อยากให้ปลาเรียนว่ายน้ำออนไลน์บ้าง
ช่วยกันสร้างธุรกิจอันสดใส
เพื่อให้ปลาว่ายน้ำอย่างปลอดภัย
เงินที่เก็บหายไปไหนพบตา
- 3 พันทองเรียนว่ายน้ำออนไลน์น้อง
รับรองต้องสนุกสุดใส
รับสมัครดูแลอย่างเร็วไว
จะได้เป็นขวัญใจในวันนี้
- 4 ปลาทองเรียนว่ายน้ำออนไลน์หรือ
นี่หรือคือสุขใจในวิถี
โอชีวิตของฉันทันแสนดี
คงไม่มีใครเป็นเช่นนั้นเลย
4. เพนกวินเดินเที่ยวเยาวราช (a penguin strolls through
Yaowarat, Bangkok's Chinatown)
- 0 เพนกวินเยาวราชไปอีกครั้ง
เปี่ยมพลังยิ่งใหญ่ไม่สิ้น
มีคนรักมากมายหลายผู้คน
อีกหลายคนแวะเวียนมาทักทาย
- 1 เพนกวินเดินหลงอยู่กลางป่า
ฝูงนกน้อยบินมาสนุกสนาน
เที่ยวเดินเล่นเยาวราชอย่างสำราญ
ผู้คนพล่านอาหารทั่วย่านนั้น
- 2 เพนกวินเยาวราชย่านฟ้ากว้าง
เป็นเส้นทางดงกลางไพรสนธ
มีคนรักมากมายตั้งหลายคน
มีผู้คนมากมายเดินตามมา
- 3 เพนกวินเดินเที่ยวงานฉลอง
ย่านห้างทองเมืองกรุงฉลิหา
มีของกินมากมายในมรรคา
ดาวบนฟ้างามเด่นสะดุดตา
- 4 เพนกวินเที่ยวเยาวราชป่า
ชมหมู่ฝูงดาราท้าแสงสี
มีผู้คนโดดเด่นดูเด่นดี
แต่ไม่มีเพื่อนใครที่สนใจ
5. ตุ๊กตุ๊กบนดาวอังคาร (a tuk-tuk on Mars)
- 0 ตุ๊กตุ๊กบนดวงจันทร์จินผิดหวัง
เลยต้องนั่งมองไปใจสับสน
การกระทำที่ท่าซำกมล
ไม่ใช่คนมาจากดาวอังคาร
- 1 ตุ๊กตุ๊กสามล้อบนดาวเสาร์
รดตุ๊กเขาทำให้เราเพื่อผินหา
ตุ๊กตุ๊กดาวอังคารปั่นไปมา
แล้วนำพาหลงทางอยู่แสนไกล
- 2 ตุ๊กตุ๊กบนดวงจันทร์วันฟ้ากว้าง
มองเส้นทางต่างอย่างไรไม่สับสน
ตุ๊กตุ๊กขับไปตามใจตน
ฉันทันเป็นคนมาจากดาวอังคาร
- 3 เป็นตุ๊กคนบนดาวอันพรพราว
ตุ๊กตุ๊กดูดาวสกาใส
ตุ๊กตุ๊กราตรีที่ยาวไกล
ตุ๊กตุ๊กท่องไปในดวงจันทร์
- 4 ตุ๊กตุ๊กบนฟ้ามองท้องฟ้า
ตุ๊กตุ๊กบนฟ้าหาไรที่
ตุ๊กตุ๊กบนดาวดวงนี้ดี
แต่ไม่มีตุ๊กแกบนดวงจันทร์
6. ยักษ์วัดแจ้งเล่นโทรศัพท์ (the giant guardian of Wat Arun

plays with a phone)

- 0 ยักษ์วัดแจ้งโทรศัพท์มือถือหาย
จึงถูกขังทั้งไว้ให้สับสน
โทรศัพท์โทรหาหาตน
มีหลายคนติดต่อมาก่อวณ
- 1 มาพบยักษ์วัดแจ้งที่วัดแจ้ง
ได้แสดงโทรศัพท์มือถือใหม่
แล้วแอบเล่นโทรศัพท์ในทันใด
เลยวิ่งไปตามพระเกือบไม่ทัน
- 2 ยักษ์วัดแจ้งโทรศัพท์ใครรู้บ้าง
เล่นหน้าตาโทรศัพท์ให้สับสน
โทรศัพท์มือถือของใจตน
จนเสียจนสงสัยไม่รู้ตัว
- 3 ยักษ์วัดแจ้งโทรหาหาขอเรื่อง
เสียงนกร้องเรียกหาพาหวันไหว
โทรศัพท์มาหาอย่างเร็วไว
แต่สัญญาณหายไปไม่กลับคืน
- 4 ยักษ์วัดแจ้งชอบแอบเล่นมือถือ
คนชาวบ้านรำลือคือชื่อผี
โทรศัพท์ไปไหนก็ไม่มี
ใครรู้ตัวตัวมาก่อวณ
7. คนหลอกผี (a person who frightens ghosts)
- 0 ผีหลอกคนผีหลอกผีท่านทั้งหลาย
ผีหลอกคนมากมายให้สับสน
ผีหลอกคนหลอกถึงผีหลอกคน
ผีหลอกผีหลอกคนจนงมงาย
- 1 ผีจะหลอกอย่างไรที่ไหนเล่า
นึกว่าเรานั้นน่ากลัวยิ่งกว่าผี
เห็นผีที่ไรผาทุราตรี
เพราะหน้าตาคนนี่ผีไม่กลัว
- 2 ผีหลอกคนเพราะอยากเห็นเป็นผีสาว
ผีจึงได้ตัวอย่างมาว่าหนงผี
ผีหลอกคนหลอกผีทุราตรี
ผีไม่มีอะไรที่น่ากลัว
- 3 ผีจะหลอกอย่างไรก็ไม่ได
ผีมันโผล่เข้าไปในหนังหัว
ผีมันบอกออกมาข้างน่ากลัว
คนอะไรพันพัวกลัวเหลือเกิน
- 4 ผีจะหลอกอย่างไรไม่เข้าท่า
ผีก็ไม่เห็นหน้าว่าเป็นผี
ผีรู้ว่าคนทำชั่วชั่ว
ผีจึงหนีไปจากคนหลอกหลวง
8. ทุเรียนบนสถานีอวกาศ (durian on the space station)
- 0 สถานีอวกาศก็พันครั้ง
เธอก็ยังเฝ้ารอเธอรู้ไหม
กินทุเรียนบนผืนทุกวันไป
ด้วยหัวใจมุ่งมั่นในความรัก
- 1 ทุเรียนทอดยังหล่นบนท้องฟ้า
โปรดประทานส่งมาพาฉันทันสงสัย
สถานีอวกาศนั้นแสนไกล
แต่วันนี้เธอไปไม่พบเจอ
- 2 สถานีอวกาศชอบฟ้ากว้าง
ระยะทางยังห่างไกลให้สับสน
ทุเรียนน้อยลอยไปในใจคน
ทุเรียนบนดวงจันทร์นั้นแสนไกล

- 3 เห็นทุเรียนหล่นลงบนท้องฟ้า
ต้นตระหนกขึ้นมาพาใจหาย
ขณะเธอตกจากเครื่องบินไป
ข่าวว่าเธอจากไปไม่กลับมา
- 4 เห็นทุเรียนหล่นร่วงบนท้องฟ้า
คนตะโกนขึ้นมาว่าเป็นผี
เธอก็เลยจากไปไม่มีไยดี
คงไม่มีอีกแล้วอีกต่อไป
9. กบเป็นดีเจ (a frog works as a DJ)
- 0 กบอยากเป็นดีเจให้ดูสักครั้ง
ถ้าเธอลงมาฟังจะดีไหม
ช่วยร้องเพลงกล่อมกันทุกวันไป
หรือทำงานก็ได้ไม่กังวล
- 1 ชาวกบเป็นดีเจที่ไหนเล่า
ฟังข่าวสาววิทย์มาจากไหน
ทั้งที่วิทย์ฟังกันไป
ถามว่าใครฟังบ้างไม่รู้เลย
- 2 กบอยากเป็นดีเจใหม่ให้ใครบ้าง
แต่หลายอย่างลองเปิดฟังดูสักหน
จะเพียรฝึกฝนตนอย่างอดทน
คงมีคนสนใจมาดูแล
- 3 เป็นดีเจจำเป็นต้องฟังเขา
คนนอกห้อยอย่างเราเศร้าไปไหม
เพราะชีวิตช่วงนี้ไม่มีใคร
กบจะร้องทำไมให้ซ้ำใจ
- 4 กบเป็นดีเจได้ในเวลา
อาจต้องใช้เวลามากกว่า
ว่าชีวิตการฟังเป็นเรื่องดี
เพราะไม่มีใครเขามารบกวน
10. หมีแพนด้าตักบาตร (a panda offers alms to monks)
- 0 หมีแพนด้าตักบาตรวันพระขึ้นปีใหม่
ส่งความสุขมากมายสำแดงผล
สิ่งศักดิ์สิทธิ์ปกป้องคุ้มครองตน
ให้ทุกคนปลอดภัยอันตราย
- 1 หมีแพนด้าตักบาตรครบพรรษา
ในเวลาล้านวันเกิดประเสริฐศรี
ขอหมีแพนด้ามีความสุขพบสิ่งดี
ขอให้นี้มีสุขทุกคืนวัน
- 2 หมีแพนด้าตักบาตรวันพระละเว้นบ้าง
มองเส้นทางที่สว่างสร้างกุศล
ปฏิบัติกิจธรรมนำกมล
ให้หลายคนได้สุขไร้ทุกข์ปน
- 3[†] หมีแพนด้าตักบาตรในวันพระ
อย่าละเว้นวันพระละเว้นได้
เรื่องตักบาตรตักบาตรว่ากันไป
เพื่อส่งให้หมีแพนด้าสบายใจ
- 4 หมีแพนด้าตักบาตรมาดีหักว่า
เจ้าหมีแพนด้าถามว่าทำไม
หมีกินแล้วทั้งไปมีไยดี
เพราะไม่มีใครเห็นเป็นเช่นนี้
11. เมฆขอยืมร่ม (a cloud asks to borrow an umbrella)
- 0 ร่มขอยืมร่มขอยืมร่มที่ให้
ร่มขอยืมร่มใครเขาไม่สน
ร่มขอยืมร่มตนทนอดทน
ร่มขอยืมร่มตนคนรำคาญ
- 1 ร่มขอยืมร่มร่มร่มในเก่า
ร่มของเราเขาขอยืมร่มเราให้
ร่มของเขาเราขอยืมแล้วทำไม
ร่มของใครกันหนอที่ขอยืม
- 2 ร่มขอยืมร่มวอนให้เห็นใจบ้าง
ร่มอ้างว้างใจมันเหงาเขาลึกใส
ร่มของจันคนดีหนีจากไกล
ร่มที่เธอจากไปไม่หวนคืน
- 3 ร่มขอยืมร่มร่มร่มก่อนเก่า
ร่มขอยืมร่มเราร่มวันไหน
ร่มขอยืมร่มนี้ร่มครั้งใด
ร่มขอยืมร่มใหม่ร่มของใคร
- 4 ร่มขอยืมร่มดวงใจจากปลายฟ้า
ร่มขอยืมร่มสัจญาคิดถึงพี่
ร่มขอยืมร่มน้ำใจในไมตรี
ร่มขอยืมร่มคนที่ห่วงใย
12. นาฬิกาที่เดินถอยหลัง (a clock that runs backwards)
- 0 นาฬิกาที่เดินถอยหลังทุกครั้ง
ทุกนาฬิกายังฟังยังคงฝัน
วันเวลาผ่านไปไม่ต่างกัน
ส่วนตัวจันก้าวต่อไปก้าวเดิน
- 1 นาฬิกาที่เดินถอยหลังตั้ง
เป็นพลังแห่งความฝันอันยิ่งใหญ่
จันหันมองนาฬิกาที่เดินไป
เพื่อขับเคลื่อนก้าวใหม่ให้ก้าวเดิน
- 2 นาฬิกาที่เดินถอยหลังไปบ้าง
เดินตามทางเดินต่อไปไม่ถึงฝั่ง
เธอจากไปในคืนวันใจพัง
ยังรู้สึกทุกครั้งที่กำลังเดิน
- 3 นาฬิกาที่เดินถอยหลังครั้ง
พร้อมกับการถอยหลังเพื่อก้าวใหม่
นาฬิกายังเดินก้าวเดินไป
แต่พลังของใจไม่หยุดเดิน
- 4 นาฬิกาที่เดินถอยหลังรั้ง
มีอาจจุดความหวังตามวิถี
เมื่อก้าวถึงปลายทางอันแสนดี
ก็ไม่มีเวลาให้ก้าวเดิน
13. สายลมสีชมพู (a pink breeze)
- 0 สายลมพัดสีชมพูให้คิดถึง
ยังคะนึงถึงเธอเพื่อหวนไหว
แม้ตัวจันห่างไกลกับคนไกล
ไม่รู้เลยมีใครอยู่ใกล้เธอ
- 1 สายลมพรมพัดผ่านผ่านผ่านฟ้า
หมู่ดาราหรือหมู่ดาวพราวไสว
ฝากสายลมสีชมพูที่อยู่ใจ
ส่งมาให้ด้วยรักมอบแต่เธอ
- 2 สายลมพัดสีชมพูมาเคียงข้าง
ยามอ้างว้างยังคิดถึงอยู่เสมอ
ทุกเวลานาทีได้พบเจอ
มีเพียงเธอผู้เดียวเพียงผู้เดียว
- 3 สายลมพรมพัดมาพาใจเจ้า
ให้จันคอยคลายเหงาเฝ้าหวนไหว
คิดถึงเธอเพื่อฝันทุกวันไป
จากดวงใจดวงนี้ที่รักดี
- 4 สายลมพรมพลิวผ่านผ่านผ่านฟ้า
หมู่ดาราลอยไกลจากแดนสรวง
สีชมพูสดใสในดวงใจ
ตั้งดวงดาวกลางห้วงแห่งดวงใจ

14. ดาวเทียมคิดถึงบ้าน (a satellite misses home)

- 0 มองดาวเทียมคิดถึงบ้านยังคิดถึง
ใครคนหนึ่งซึ่งอยู่บ้านไกล
ความคิดถึงเคยฝากจากคนไกล
ยามที่เขากลับมา
- 1 ดาวเทียมเยี่ยมบ้านนาพนาป่า
คำสัญญาถึงคนไกลจากถิ่นฐาน
ใจคิดถึงคิดถึงบ้านสายธาร
คิดถึงบ้านวันเก่าเราเคยลิ้ม
- 2 ส่งดาวเทียมคิดถึงบ้านแม้อยู่ห่าง
ระยะทางสุดแสนไกลใจสับสน
ความคิดถึงดวงน้อยคอยกมล
คิดถึงคนห่างไกลไม่กลับมา
- 3 ดาวเทียมส่องบ้านเราในวันเหงา
คิดถึงบ้านหลังเก่าเขาเล่าใหม่
คิดถึงจิ้งจอกตัวที่มีใจ
คิดถึงคนอยู่ไกลไม่ไกลกัน
- 4 ดาวเทียมเยือนบ้านนาทองนาฟ้า
คิดถึงบ้านเถียงนาหมาเห่า
ยังคิดถึงทุ่งนาทุกนาที่
ฟังจ๊ออุ๋งอุ๋งใจ

15. หิมะตกกลางสงกรานต์ (snow falls during Songkran, the Thai New Year water festival)

- 0 เจอหิมะตอนสงกรานต์น้ำดาไหล
แอมน้ำตาร้องไห้ใจสับสน
เห็นหิมะตกมาพาทักใจ
คิดถึงคนเคยรักจากไกล
- 1 เห็นหิมะตกมาก็นึกว่า
คงจะมีเวลาที่ดูสดใส
หิมะตกกลางสงกรานต์สะท้านใจ
อยากจะไปหิมะสักครั้งจัง
- 2 เห็นหิมะตอนสงกรานต์ใครบ้าง
หิมะสร้างสับสนอยู่ที่ไหน
พอหิมะตกมารีบบอกไป
ว่าอยู่ไหนได้พบประสมกัน
- 3 หลังจากผ่านสงกรานต์อันแสนหนาว
รู้สึกเหน็บหนาวครวญวันไหว
พอหิมะตกมาต้องทำใจ
เพราะนึกไปโลกนี้มีใคร
- 4 จะตกหลังสงกรานต์ฉันไม่ว่า
ได้หิมะกลับมาพาทักใจ
แต่หิมะตกมาดังหลายปี
ดวงฤทัยคนนี้ไม่มีเทียม

16. เอไอแต่งกลอน (an AI writes verse)

- 0 โอฟังรู้วักกลอนนี้มีความหมาย
ไอนิดหัวใจไม่สับสน
ไอรักทุกคนทุกตัวตน
ไอเป็นคนจริงใจไม่หลอกลวง
- 1 ไออยากไปเมืองนอกเพื่อพักผ่อน
ไอแต่งกลอนตามประสาอยู่ที่ไหน
ไอก็ชอบธรรมชาติที่รักใจ
ไอจะช่วยผ่อนคลายให้คลายร้อน
- 2 ไอไม่เคยคิดรำพึงถึงใครบ้าง
ไอยังยืนอยู่อย่างว่างและสับสน
ไอคิดถึงทุกคนทุกตัวตน
ไอเป็นคนอ่อนไหวในเวลา

- 3 อดตอบแทนความรักที่มอบให้
ไอจะมอบหัวใจให้ไปทั่ว
ไอรักทุกคนช่วงทุกช่วงตัว
ไอไม่กลัวใครไหนนอกจากยู
- 4 ไอก็คงแต่งได้อย่างนั้นหรือ
ไอจะถือตัวว่าเป็นผี
ไอเชื่อว่าหากว่าเจอคนดี
ไอไม่มีเพื่อนใครให้บอกมา

17. ห้องเรียนใต้ทะเล (a classroom under the sea)

- 0 เปิดห้องเรียนใต้ทะเลในตอนใหม่
ให้สนุกหัวใจไม่สับสน
ประสบการณ์ชีวิตอุทิศตน
เป็นหนึ่งในคนที่อยู่ทะเล
- 1 ขอขอบคุณน้ำใจที่มาให้
มีน้ำใจไม่ตรีจิตอย่าคิดหนี
มิตรภาพในบ้านนี้ไม่มีปี
ขอบคุณมากไมตรีที่ตอบมา
- 2 ฉันยังอยู่หัวใจใต้ทะเลกว้าง
แม้อ้างว่างอยู่แสนไกลใจสับสน
แต่ยังหวังฝันใฝ่ในกมล
อยากเป็นคนที่อยู่เคียงเธอ
- 3 อยากจะเรียนห้องเรียนทบทวนใหม่
แต่โรงเรียนเปิดไว้ให้ศึกษา
ในหกลีบนี้ไม่มีมา
เพราะวิชาเราน้อยต่อปัญหา
- 4 เมื่อวันหัวใจใฝ่ศึกษา
จึงรู้ว่าครูนี้ไม่มีหนี
แต่ก็ชอบตอบไปโนวจ
ขอขอบคุณไมตรีที่มีมา

18. ความคิดของเครื่องคิดเลข (a calculator's thoughts)

- 0 เลขของคนมีอำนาจในความคิด
จะบวกผิดลบถูกตามใจฝัน
จะคิดไปเท่าไรไม่ต่างกัน
แต่เพราะมันตัวเลขที่ให้มา
- 1 เลขของคนคิดค้นมันไม่ผิด
แค่เราคิดสูตรผิดเพี้ยนจึงเพี้ยนได้
เพราะความคิดของเจ้าของที่เขียนไป
คำนวณไว้อย่างไรก็ไม่เป็น
- 2 เลขของหนึ่งบวกลบได้ไม่แตกต่าง
จึงอาจสร้างตัวเลขไว้ให้สับสน
แต่ก็เป็นมุมมองความคิดตน
จึงต้องค้นวิธีมาคำนวณ
- 3 เลขของคนเขียนมาใช้ว่าผิด
เพียงแค่คิดแตกต่างมันแปลกใหม่
เลขที่เห็นใจใจให้ออกไป
รับไม่ได้เท่าไรอย่าว่ากัน
- 4 เลขของเครื่องแสนสูงเสียดเขียวหรือ
เลขนั้นคืออะไรในใจผี
คงเป็นเพราะตัวเองดวงไม่ดี
จึงไม่มีเลขที่มากำหนด

19. สะพานข้ามเวลา (a bridge across time)

- 0 สะพานข้ามวันเวลาอีกคราครั้ง
จะได้ยรรยงยิ้มที่สดใส
มีเธอยืนเคียงข้างอยู่กลางใจ
เป็นสะพานทอดใหม่ให้ก้าวเดิน

- 1 สะพานข้ามเวลาสัญญาว่า
เมื่อขึ้นมาพบหนทางอันสดใส
จะผ่าอุปสรรครักข้ามมันไป
เพื่อเริ่มต้นวันใหม่ไม่เคยลืม
- 2 สะพานข้ามถึงเวลามาพบสร้าง
บนเส้นทางความมืดมน ให้สับสน
กระตือรือร้นลอยไปจากใจตน
มีแต่คนติดตามคอยห่วงใย
- 3 สะพานข้ามเวลามาบอกกล่าว
สะพานข้ามเรื่องราวที่สดใส
เป็นสะพานทอดฝันอันยาวไกล
สะพานข้ามหัวใจให้ยืนยาว
- 4 สะพานข้ามเวลามาพาฝัน
สร้างรอยยิ้มให้กันวันฝันนี้
ความจริงใจมอบไว้ในหัวใจ
จากคนที่ฉันรักสลับใจ

20. หลุมดำในชั้นหนังสือ (a black hole on the bookshelf)

- 0 หลุมดำในชั้นหนังสือในชั้นหนึ่ง
ยังหวานซึ้งตรึงใจไปอีกหน
ความทรงจำซ่อนไว้ในกมล
ของหลายคนผ่านกาลเวลา

- 1 สะท้อนผ่านหนังสือในชั้นลึก
ให้ใจนึกถึงพลังมหาศาล
บทกวีอมตะนิรันดร์กาล
ที่ฉันอ่านมาได้ในบทกลอน
- 2 ภาพหลุมดำในหนังสือชั้นสรรค์สร้าง
อยากจะสร้างความทรงจำไว้อีกหน
สะท้อนความรู้สึกจากใจตน
ที่มากล้นพ้นไปในวันวาน
- 3 เธอคือหนึ่งหนังสือในชั้นนั้น
ผู้สรรค์สร้างสุ่มอันยิ่งใหญ่
ทุกทุกบททั้งหมดที่เขียนไป
รู้สึกประทับใจในบทกลอน
- 4 เธอได้อ่านหนังสือในชั้นนั้น
ในดวงจิตของฉันไซ้ไหมนี้
ถึงจะผ่านไปในวันนี้
ก็ไม่มีสิ่งใดให้จดจำ